

인페인팅을 활용한 모아레 높이 위상 값 복원

김태정¹⁾, 김찬희²⁾, 박태형³⁾

충북대학교 정보통신공학부¹⁾, 충북대학교 대학원 제어로봇공학전공²⁾, 충북대학교 지능로봇공학과³⁾

Moire Height Phase Value Reconstruction using Inpainting

Tae-Jung Kim¹⁾, Chan-Hoe Kim²⁾, Tae-Hyoung Park³⁾

Dept. of Information and Communication Engineering, Chungbuk National Univ.¹⁾

Dept. of Control and Robot Eng., Chungbuk National Univ.²⁾

Dept. of Intelligent Systems and Robotics, Chungbuk National Univ.³⁾

Abstract - 본 논문에서는, 모아레 패턴이 투영된 PCB 위상 맵의 높이 측정을 방해하는 요소인 빛 반사와 그림자 영역을 제거 및 재구성하고자 딥러닝 모델인 적대적 생성 신경망 (Generative Adversarial Networks, GAN) 모델을 설계하였습니다. 적대적 생성 신경망은 실재와 같은 이미지를 생성하고, 원하는 형태로 스타일 변경이 가능합니다. 논문에서는 적대적 생성 신경망의 이러한 특징을 활용하여 적대적 생성 신경망을 접목한 인페인팅 (Inpainting) 모델을 통해 재구성된 이미지에서 더 나아가 2D Unwrap을 통해 최적의 높이 위상 값을 복원하였다.

1. 서 론

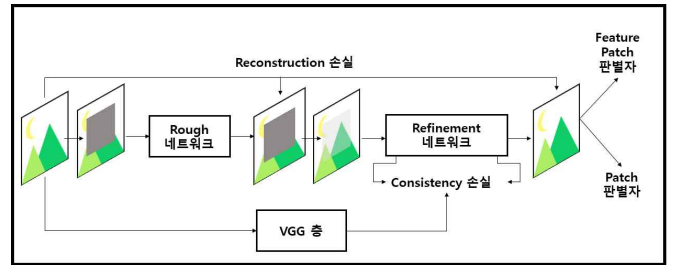
모아레 패턴이란 주기적인 무늬의 형태를 띄며 이들이 겹쳐 나타나서 더 큰 무늬를 의미하며 0, 90, 180, 270도 4각도에서 이동된 이미지로 위상 맵을 계산하여 높이를 추정한다. 딥러닝 생성 모델인 GAN은 그림 1처럼 입력된 이미지를 가지고 실재와 같은 이미지를 생성한다. 논문에서 사용될 모델은 적대적 생성 신경망 모델에서 발전된 조건부 적대적 생성 신경망 (, Pix2Pix) 모델로 그림 1과 같이 이미지 생성에 그치지 않고 조건을 추가하여 원하는 스타일의 이미지 생성이 가능하다.

본 논문에서는 모아레 패턴 PCB 이미지를 위상 맵 (Phase Map)으로 변환하고 이를 2D 언래핑(Unwrap)을 통해 높이 위상 값을 측정 하고자 한다. 이 과정에서 이미지속 그림자 영역 및 빛 반사 영역으로 인해 높이 측정에 오차가 생기고, 적대적 생성 신경망을 접목한 인페인팅 모델을 사용해 해당 영역을 복원 및 올바른 높이 측정을 목표로 한다. Hongyu가 제시한 적대적 생성 신경망 모델이 CSA 인페인팅 모델을 활용하여 모아레 패턴 PCB 이미지 속 그림자 및 빛 반사가 있는 영역을 마스크 영역으로 지정하여 그림자 및 빛 반사가 없는 이미지로 복원 및 생성하였고, 2D Unwrap을 통해 높이 위상 값을 계산하여 위상 손실함수를 추가하였다[1].

Jiahui가 제시한 적대적 생성 신경망 모델은 CSA 인페인팅 모델과 달리, Contextual Attention을 활용한 인페인팅 모델로, 성능 비교를 통해 최적의 모델을 찾고자 하였다[2].

2. 본 론

2.1 CSA 인페인팅



〈그림 2〉 CSA 인페인팅 모델 구조

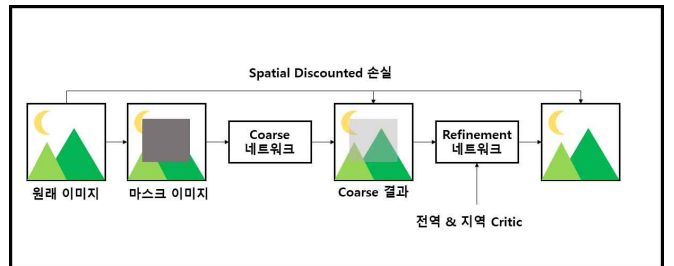
그림 2와 같이 논문 [1]에서 제시한 적대적 생성 신경망 모델을 접목한 인페인팅 모델은 사각형 혹은 랜덤의 마스크 영역으로 가려진 손상된 이미지에서 원본 이미지로 복원하기 위한 모델이다.

해당 논문에서는 Rough 네트워크와 Refinement 네트워크로 나뉘어 총 2번에 걸쳐 이미지 복원이 진행된다. 논문에서 제시한 Refinement 네트워크에는 CSA 층을 추가하여 이미지의 특정 손상된 부분을 이미지의 문맥을 고려하여 복원 및 생성을 진행한다. 마지막으로 복원된 이미지에 Patch 판별자를 통해 결과 이미지를 한번 더 최적화한다.

논문에서 제시하는 손실함수는 수식 1과 같이 Reconstruction 손실, Consistency 손실, Adversarial 손실 총 3가지의 손실함수를 더하고 각각에 람다 값을 곱해준 형태로 구성되어 있다.

$$L = \lambda_r L_{re} + \lambda_c L_c + \lambda_d D_R \quad (1)$$

2.2 Contextual Attention 인페인팅

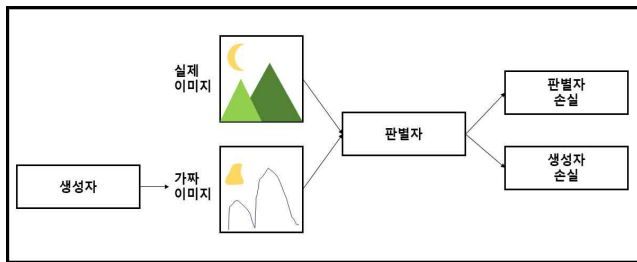


〈그림 3〉 Contextual Attention 인페인팅 모델 구조

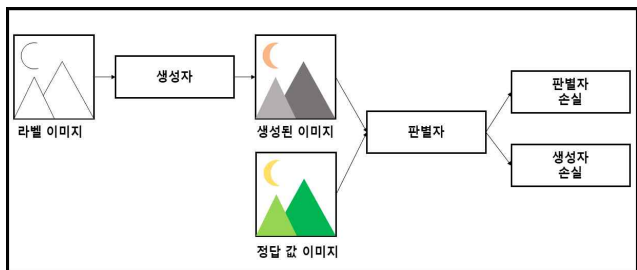
그림 3 과 같이 논문 [2]에서 제시한 적대적 생성 신경망 모델을 접목한 인페인팅 모델은 마찬가지로 사각형 혹은 랜덤 마스크 영역으로 가려진 손상된 이미지를 원본 이미지로 복원하기 위한 모델이다.

해당 논문에서는 Coarse 네트워크, Refinement 네트워크로 나뉘어 2번에 걸쳐 이미지 복원이 진행된다. 이때 Contextual Attention을 통해 알려진 영역의 정보로부터 손상된 영역에 대한 유의미한 특징을 복사하여 생성되는 영역에 디테일을 준다.

이후 복원된 이미지를 전역 판별자를 통해 출력된 전체 영상에 대한 진위 여부를 판별하고, 지역 판별자를 통해 출력 영상에 대해서만 진위여부 판별을 진행하여 전체적인 영상의 문맥과 복원된 영역의 질을 높이도록 구성되어 있다.




(a) 적대적 생성 신경망 모델 구조



(b) 조건부 적대적 생성 신경망 모델 구조

〈그림 1〉 생성 신경망 모델 구조



〈그림 4〉 정답 이미지를 활용한 마스크 이미지

2.3 적용 기법

본 논문에서는 모델 학습에 앞서 GT 를 통한 정확한 높이값을 측정하고, 모아레 패턴만으로 구한 위상 맵 이미지인 참조 이미지를 가지고 그림자 및 빛 반사가 없는 PCB 모아레 위상 맵 이미지를 생성하였다. 이 이미지를 정답 이미지로 설정하였고 그림 4와 같다.

또한 마스크 영역을 설정하기 위한 기준을 정하였다. 논문 [1]에서는 마스크 영역을 사각형으로 통일하거나 램덤으로 지정하여 마스크로 가려진 영역에 대한 복원을 진행하기 때문에 그림자 및 빛 반사 영역을 마스크 영역으로 지정하기 위한 전처리 작업을 추가하였다. 마스크 영역을 지정하기 위해 0, 90, 180, 270도 4각도에서 이동된 PCB 이미지를 통해 0과 가까운 픽셀 값을 가진 어두운 영역과 255와 가까운 픽셀 값을 가진 밝은 영역을 각각 그림자 영역, 빛 반사 영역으로 지정하였다. 각각의 영역을 255 픽셀 값으로하여 마스크 영역 이미지로 만들었고, Opencv의 포폴로지 기법 OPEN과 CLOSE를 통해 빈 부분을 채우고 불필요한 노이즈 값을 제거하였다. 이후 마스크 영역 이미지와 학습을 위한 정답 이미지를 합성함으로써 생성된 마스크 이미지는 그림 4와 같다.

이후 모델 학습을 위해 그림 4와 같은 정답 이미지를 입력으로하여 이미지 복원을 진행하였다. 모델 학습을 통한 마스크 영역에 대한 이미지 복원 과정에서 복원된 위상 맵 이미지에 대한 높이 위상 값을 구하기 위해 중간 과정으로 2D Unwrap 을 넣었다. 참조 이미지와 복원된 이미지 모두 2D Unwrap을 진행하였고, Unwrapping 된 두 이미지의 차이를 통해 복원된 이미지의 높이 위상 값을 구했다. 참조 이미지와 정답 이미지 또한 2D Unwrap을 진행하였고, Unwrapping 된 두 이미지의 차이를 통해 정답 이미지의 높이 위상 값을 구함으로써 복원된 이미지와, 정답 이미지의 높이 위상 값을 얻었다.

이후 두 이미지의 높이 위상 값의 차이를 픽셀로 계산하여 위상 손실함수로 정하였다. 수식 2와 같이 기존의 손실함수에서 Reconstruction, Consistency, Adversarial 손실함수를 더한 손실함수를 제안한다. 이를 통해 학습에 있어서 해당 손실을 줄이기 위한 방향으로 파라미터 업데이트가 진행이 되며, 이 과정에서 높이 위상 값이 최소가 되는 방향으로 학습을 진행시켰다.

$$L = \lambda_r L_{re} + \lambda_c L_c + \lambda_d L_R + L_u \quad (2)$$

3. 실험

3.1 실험 환경

본 논문에서는 i7 기반에 CPU를 사용하였고 GPU는 GTX Geforce 3080을 사용하여 실험을 진행하였다. 실험에 사용한 데이터는 빛을 반사하는 소재를 가진 PCB 기판을 제작하여 모아레 패턴 생성기 및 카메라 기구부에서 직접 촬영한 데이터로 실험을 진행하였다.

실험에서는 PCB 이미지에 대한 여러 증강 기법을 통해 20,000 여장의 이미지를 생성하였고, 학습 횟수는 적대적 생성 신경망의 성능지표인 FID 수치가 더 이상 줄어들지 않을때까지 학습시켜 약 12,000번 정도, 학습률은 0.0002를 시작으로 점차 감소시켜가며 최적의 값인 0.0001381로 설정하여 학습을 진행하였다.

3.2 실험 결과

실험 결과, 그림 5과 같이 정답 이미지를 입력으로 넣었고, 모델은 마스크 영역을 지정하여 마스크 이미지를 생성하였다. 학습을 진행하면서 복원된 위상 맵 이미지를 2D Unwrap 을 통해 그림 6과 같이 복원된 이미지, 정답 이미지에 대한 높이 위상 값을 계산하였고, 정답 이미지의 높이 위상 값과의 차이를 고려하여 파라미터를 업데이트 해주었다. 최종적으로 학습된 모델에 그림자 및 빛 반사가 존재하는 PCB 모아레 위상 맵 이미지를 입력으로 넣었고, 결과로 복원된 이미지에 2D Unwrap을 통한 복원된 높이 위상 값을 얻었다.

〈표 1〉 복원된 위상 값 이미지, 정답 위상 값 이미지

	CSA 인페인팅	Contextual Attention 인페인팅
생성된 이미지		
생성된 높이 위상 값 이미지		
정답 높이 위상 값 이미지		
높이 위상 값 차이의 평균	0.02	0.10

Patch 관별자를 이용한 또 다른 모델인 Contextual Attention 인페인팅 모델과 비교하여 그림 6과 같은 높이 위상 값 이미지의 높이 위상 값의 차이를 비교해보았고, 생성된 이미지의 높이 위상 값과 정답 이미지의 높이 위상 값 차이를 비교해본 결과 CSA 인페인팅 모델이 약 305만 정도(전체 픽셀값으로 나누면 0.02)의 픽셀 차이를 보일 때, Contextual Attention 인페인팅 모델은 약 1500만 정도(전체 픽셀값으로 나누면 0.10)의 픽셀 차이를 보임을 통해 CSA 인페인팅 모델이 더 높은 성능을 보였다는 걸 확인할 수 있다.

4. 결 론

본 논문에서는 PCB 기판의 모아레 패턴 위상 맵에서의 높이 위상 값 복원을 위해GAN 기반의 인페인팅 모델을 이용하였다. 실험을 진행하는데 있어 최적의 높이 위상 값 복원을 위해 마스크 이미지 설정을 바꾸어 가며 결과 비교를 진행했고, 이후 모델의 구조를 일부 변경하여 컨볼루션 신경망(Convolutional Neural Network, CNN) 모델 기반의 VGG16 모델에서 VGG19 모델로 변경 및 일부 파라미터 값을 조정하였다.

실험을 통해 높이 위상 값 차이를 비교해본 결과 적대적 생성 신경망을 이용한 모델 중 CSA 인페인팅 모델이 높이 위상 값을 가장 잘 복원한 것을 확인할 수 있다. 추후 연구에서는 해당 높이 위상 값 비율을 실제 높이 값으로 바꾸어 실제 높이와의 오차를 구하겠다.

[감사의 글]

본 논문은 2023년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받고(NO.2022-0-00795, AI 기술을 적용한 고성능 모아레 패턴 방식 3D카메라 시스템 개발), 과학기술정보통신부 및 정보통신기획평가원의 지역지능화혁신인재양성(Grand ICT연구센터) 사업(IITP-2023-2020-0-01462)의 연구결과로 수행되었음.

[참 고 문 헌]

- [1] Liu, Hongyu, et al. "Coherent semantic attention for image inpainting." *Proceedings of the IEEE/CVF International Conference on Computer Vision*. p. 4170-4179. 2019.
- [2] Yu, Jiahui, et al. "Generative image inpainting with contextual attention." *Proceedings of the IEEE conference on computer vision and pattern recognition*. p. 5505-5514. 2018.